Экономия на эвалах

Самая большая команда

Майская школа по статистике в октябре

25 октября 2026 г.

Содержание

1. Постановка задачи
2. Предположения модели
3. Вывод вероятности ошибки
4. Оценивание параметров
5. Заключение

Постановка задачи

1. Имеется **70 релизов** LLM-модели.

Постановка задачи

1. Имеется **70 релизов** LLM-модели.
2. Каждый релиз проверяется на **40 эвалах**.

Постановка задачи

1. Имеется **70 релизов** LLM-модели.
2. Каждый релиз проверяется на **40 эвалах**.
3. Каждый эвал запускается **5 раз**.

Постановка задачи

1. Имеется **70 релизов** LLM-модели.
2. Каждый релиз проверяется на **40 эвалах**.
3. Каждый эвал запускается **5 раз**.
4. Стоимость запуска зависит от эвала.

Постановка задачи

1. Имеется **70 релизов** LLM-модели.
2. Каждый релиз проверяется на **40 эвалах**.
3. Каждый эвал запускается **5 раз**.
4. Стоимость запуска зависит от эвала.

Цель

Сократить расходы на оценку качества модели, уменьшив количество прогонов и сохранив точность обнаружения ошибок.

Постановка задачи

1. Имеется **70 релизов** LLM-модели.
2. Каждый релиз проверяется на **40 эвалах**.
3. Каждый эвал запускается **5 раз**.
4. Стоимость запуска зависит от эвала.

Цель

Сократить расходы на оценку качества модели, уменьшив количество прогонов и сохранив точность обнаружения ошибок.

Ключевой вопрос

Как определить, какие эвалы и сколько раз запускать, чтобы минимизировать стоимость тестирования без существенной потери точности?

Что имеем

Наблюдаемые данные
Для каждого релиза мы наблюдаем результаты всех прогонов по каждому эвалу.

Обозначения

$$X_{i,j}^{k}$$

Результат k-го прогона на j-м эвале для i-го релиза.

Что имеем

Наблюдаемые данные
Для каждого релиза мы наблюдаем результаты всех прогонов по каждому эвалу.

Обозначения

$$X_{i,j}^{k}$$

Результат *k*-го прогона на *j*-м эвале для *i*-го релиза.

$$\begin{aligned} i &= 1, \ldots, 70 && \text{номер релиза,} \\ j &= 1, \ldots, 40 && \text{номер эвала,} \\ k &= 1, \ldots, 5 && \text{номер прогона.} \end{aligned}$$

Что имеем

Наблюдаемые данные
Для каждого релиза мы наблюдаем результаты всех прогонов по каждому эвалу.

Обозначения

$$X_{i,j}^{k}$$

Результат *k*-го прогона на *j*-м эвале для *i*-го релиза.

$$\begin{aligned} i &= 1, \ldots, 70 && \text{номер релиза,} \\ j &= 1, \ldots, 40 && \text{номер эвала,} \\ k &= 1, \ldots, 5 && \text{номер прогона.} \end{aligned}$$

$X_{i,j}^{k} = 1$

Прогон обнаружил ошибку.

$X_{i,j}^{k} = 0$

Ошибка не обнаружена.

Предположения модели

$\theta_{i,j} \in \{0, 1\}, \qquad \theta_{i,j} = 1 \iff$ ошибка присутствует

Предположения модели

$$\theta_{i,j} \in \{0, 1\}, \qquad \theta_{i,j} = 1 \iff \text{ошибка присутствует}$$

$$\theta_{i,j} \sim \text{Bernoulli}(q_j), \qquad P(\theta_{i,j} = 1) = q_j$$

Предположения модели

$\theta_{i,j} \in \{0, 1\}, \qquad \theta_{i,j} = 1 \iff$ ошибка присутствует

$\theta_{i,j} \sim \text{Bernoulli}(q_j), \qquad P(\theta_{i,j} = 1) = q_j$

q_j не зависит от i

Предположения модели

$$\theta_{i,j} \in \{0,1\}, \qquad \theta_{i,j} = 1 \iff \text{ошибка присутствует}$$

$$\theta_{i,j} \sim \text{Bernoulli}(q_j), \qquad P(\theta_{i,j} = 1) = q_j$$

q_j не зависит от i

$$\theta_{i,j} \perp\!\!\!\perp \theta_{i',j'} \quad \text{при } (i,j) \neq (i',j')$$

Предположения модели

$\theta_{i,j} \in \{0, 1\}, \qquad \theta_{i,j} = 1 \iff$ ошибка присутствует

$\theta_{i,j} \sim \text{Bernoulli}(q_j), \qquad P(\theta_{i,j} = 1) = q_j$

q_j не зависит от i

$\theta_{i,j} \perp\!\!\!\perp \theta_{i',j'}$ при $(i,j) \neq (i',j')$

$\theta_{i,j}$ — ненаблюдаемая переменная

Предположения модели

Мы считаем, что модель-судья никогда не ошибается, то есть мы не найдём ошибок там, где их нет.

Предположения модели

Мы считаем, что модель-судья никогда не ошибается, то есть мы не найдём ошибок там, где их нет.

В связи с этим, мы считаем, что $(X^k_{i,j}|\theta_{i,j} = 1) \sim Bern(s_j)$,
иначе $P(X^k_{i,j} = 0|\theta_{i,j} = 0) = 1$

Предположения модели

Мы считаем, что модель-судья никогда не ошибается, то есть мы не найдём ошибок там, где их нет.

В связи с этим, мы считаем, что $(X^k_{i,j}|\theta_{i,j} = 1) \sim Bern(s_j)$,
иначе $P(X^k_{i,j} = 0|\theta_{i,j} = 0) = 1$

- При условии существования ошибки мы считаем, что результаты запусков эвалов независимы.

Предположения модели

Мы считаем, что модель-судья никогда не ошибается, то есть мы не найдём ошибок там, где их нет.

В связи с этим, мы считаем, что $(X^k_{i,j}|\theta_{i,j} = 1) \sim Bern(s_j)$,
иначе $P(X^k_{i,j} = 0|\theta_{i,j} = 0) = 1$

- При условии существования ошибки мы считаем, что результаты запусков эвалов независимы.
- Результаты запусков независимы между разными эвалами и разными релизами.

Данные одного релиза

Зафиксируем релиз *i*. Имеем такую таблицу:

Эвал	Наличие ошибки	Результаты прогонов
1	$\theta_{i,1}$	$X_{i,1}^1, \ldots, X_{i,1}^5$
2	$\theta_{i,2}$	$X_{i,2}^1, \ldots, X_{i,2}^5$
$\vdots$	$\vdots$	$\vdots$
40	$\theta_{i,40}$	$X_{i,40}^1, \ldots, X_{i,40}^5$

Постановка задачи

Пусть

c_j — стоимость одного прогона эвала j.

n_j — количество прогонов эвала j.

Постановка задачи

Пусть
c_j — стоимость одного прогона эвала j.
n_j — количество прогонов эвала j.

Задача оптимизации

$$\sum_{j=1}^{40} n_j c_j \to \min_{\vec{n}}$$

при условиях:

$$\begin{cases} \mathrm{FPR}(\mathbf{n}) < \alpha, \\ n_j \in \{0, \ldots, 5\}, \quad j = 1, \ldots, 40. \end{cases}$$

Постановка задачи

Пусть
c_j — стоимость одного прогона эвала j.
n_j — количество прогонов эвала j.

Задача оптимизации

$$\sum_{j=1}^{40} n_j c_j \to \min_{\vec{n}}$$

при условиях:

$$\begin{cases} \mathrm{FPR}(\mathbf{n}) < \alpha, \\ n_j \in \{0, \ldots, 5\}, \quad j = 1, \ldots, 40. \end{cases}$$

$$\mathrm{FPR}(\mathbf{n}) = P\left(\forall j : \max_{k=1,\ldots,n_j} X_{i,j}^k = 0 \;\middle|\; \exists j : \ \theta_{i,j} = 1 \right).$$

Вывод FPR: разбиение по множеству проблемных тестов

Зафиксируем релиз i. Обозначим $J = \{1, \dots, 40\}$ и события

$$G_i = \bigcap_{j \in J} \bigcap_{k=1}^{n_j} \{X_{ij}^k = 0\}, \qquad B_i = \{\exists j \in J : \theta_{ij} = 1\}.$$

При $n_j = 0$ условие отсутствия обнаружений на тесте j выполняется автоматически.
Тогда вероятность пропустить проблемный релиз равна

$$\mathrm{FPR}(\mathbf{n}) = \mathbb{P}(G_i \mid B_i) = \frac{\mathbb{P}(G_i \cap B_i)}{\mathbb{P}(B_i)}.$$

Для $A \subseteq J$ зададим точное множество проблемных тестов:

$$E_{i,A} = \bigcap_{j \in A} \{\theta_{ij} = 1\} \ \cap \ \bigcap_{j \notin A} \{\theta_{ij} = 0\}.$$

События $E_{i,A}$ попарно не пересекаются, поэтому

$$\mathbb{P}(G_i \cap B_i) = \sum_{\substack{A \subseteq J \\ A \neq \varnothing}} \mathbb{P}(E_{i,A})\, \mathbb{P}(G_i \mid E_{i,A}).$$

Вывод FPR: раскрытие произведения

По независимости тестов и условной независимости прогонов

$$\mathbb{P}(G_i \cap B_i) = \sum_{\substack{A \subseteq J \\ A \neq \varnothing}} \underbrace{\prod_{j \in A} q_j (1 - s_j)^{n_j}}_{\text{проблема есть, но не обнаружена}} \underbrace{\prod_{j \notin A} (1 - q_j)}_{\text{проблемы нет}}.$$

Раскрытие произведения даёт сумму по всем подмножествам:

$$\prod_{j=1}^{40} \left[q_j (1 - s_j)^{n_j} + (1 - q_j) \right] = \sum_{A \subseteq J} \prod_{j \in A} q_j (1 - s_j)^{n_j} \prod_{j \notin A} (1 - q_j).$$

Исключая слагаемое для $A = \varnothing$, получаем

$$\mathbb{P}(G_i \cap B_i) = \prod_{j=1}^{40} \left[q_j (1 - s_j)^{n_j} + (1 - q_j) \right] - \prod_{j=1}^{40} (1 - q_j).$$

При этом

$$\mathbb{P}(B_i) = 1 - \prod_{j=1}^{40} (1 - q_j).$$

Результат: вероятность пропуска проблемного релиза

Вероятность всех зелёных прогонов при наличии проблемы

$$\mathrm{FPR}(\mathbf{n}) = \frac{\prod_{j=1}^{40} \left[q_j (1 - s_j)^{n_j} + (1 - q_j) \right] - \prod_{j=1}^{40} (1 - q_j)}{1 - \prod_{j=1}^{40} (1 - q_j)}$$

- q_j — вероятность наличия проблемы на тесте j.
- s_j — вероятность обнаружить проблему за один прогон.
- $n_j \in \{0, \ldots, 5\}$ — число прогонов теста j.

Формула определена при $\mathbb{P}(B_i) = 1 - \prod_{j=1}^{40} (1 - q_j) > 0$. При $n_j = 0$ полагаем $(1 - s_j)^0 = 1$, в том числе при $s_j = 1$.

Правдоподобие одного теста на одном релизе

Для фиксированных релиза i и теста j:

$$L_{ij} = \left[q_j \prod_{k=1}^{5} s_j^{X_{ij}^k} (1 - s_j)^{1 - X_{ij}^k} \right]^{\theta_{ij}} \left[(1 - q_j) \right]^{1 - \theta_{ij}}.$$

$$L_j = \prod_{i=1}^{70} L_{ij}.$$

Полное правдоподобие:

$$L(\mathbf{X}, \theta; \mathbf{s}, \mathbf{q}) = \prod_{j=1}^{40} \prod_{i=1}^{70} L_{ij}.$$

Логарифм правдоподобия

Переходим к log-likelihood:

$$\log L = \sum_{j=1}^{40} \sum_{i=1}^{70} \left\{ \theta_{ij} \left[\log q_j + \sum_{k=1}^{5} \left(X_{ij}^k \log s_j + (1 - X_{ij}^k) \log(1 - s_j) \right) \right] + (1 - \theta_{ij}) \left[\log(1 - q_j) \right] \right\}.$$

Логарифм правдоподобия

Переходим к log-likelihood:

$$\log L = \sum_{j=1}^{40} \sum_{i=1}^{70} \left\{ \theta_{ij} \left[\log q_j + \sum_{k=1}^{5} \left(X_{ij}^k \log s_j + (1 - X_{ij}^k) \log(1 - s_j) \right) \right] + (1 - \theta_{ij}) \left[\log(1 - q_j) \right] \right\}.$$

Состояния θ_{ij} не наблюдаются, поэтому напрямую максимизировать $\log L$ невозможно.

Логарифм правдоподобия

Переходим к log-likelihood:

$$\log L = \sum_{j=1}^{40} \sum_{i=1}^{70} \left\{ \theta_{ij} \left[\log q_j + \sum_{k=1}^{5} \left(X_{ij}^k \log s_j + (1 - X_{ij}^k) \log(1 - s_j) \right) \right] + (1 - \theta_{ij}) \left[\log(1 - q_j) \right] \right\}.$$

Состояния θ_{ij} не наблюдаются, поэтому напрямую максимизировать $\log L$ невозможно.

Используем EM-алгоритм.

EM: E-step

Определим

$$\gamma_{ij}^{(m)} = \mathbb{E}\left[\theta_{ij} \mid X_{ij}^1, \ldots, X_{ij}^5, s_j^{(m)}, q_j^{(m)}\right].$$

EM: E-step

Определим

$$\gamma_{ij}^{(m)} = \mathbb{E}\left[\theta_{ij} \mid X_{ij}^1, \ldots, X_{ij}^5, s_j^{(m)}, q_j^{(m)}\right].$$

Так как $\theta_{ij} \in \{0, 1\}$,

$$\gamma_{ij}^{(m)} = P\left(\theta_{ij} = 1 \mid X_{ij}^1, \ldots, X_{ij}^5, s_j^{(m)}, q_j^{(m)}\right).$$

EM: E-step

Определим

$$\gamma_{ij}^{(m)} = \mathbb{E}\left[\theta_{ij} \mid X_{ij}^1, \ldots, X_{ij}^5, s_j^{(m)}, q_j^{(m)}\right].$$

Так как $\theta_{ij} \in \{0, 1\}$,

$$\gamma_{ij}^{(m)} = P\left(\theta_{ij} = 1 \mid X_{ij}^1, \ldots, X_{ij}^5, s_j^{(m)}, q_j^{(m)}\right).$$

$$\gamma_{ij}^{(m)} = \begin{cases} 1, & \exists k:\ X_{ij}^k = 1, \\ \dfrac{q_j^{(m)}(1 - s_j^{(m)})^5}{1 - q_j^{(m)} + q_j^{(m)}(1 - s_j^{(m)})^5}, & X_{ij}^1 = \cdots = X_{ij}^5 = 0. \end{cases}$$

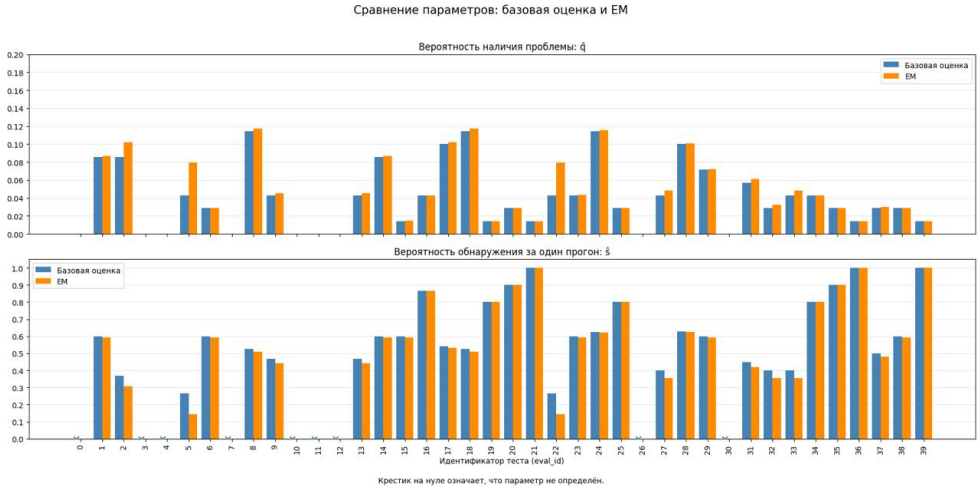
EM: M-step

После вычисления $\gamma_{ij}^{(m)}$ обновляем параметры.

$$s_j^{(m+1)} = \frac{\sum_{i=1}^{70} \gamma_{ij}^{(m)} \sum_{k=1}^{5} x_{ij}^k}{5 \sum_{i=1}^{70} \gamma_{ij}^{(m)}}.$$

$$q_j^{(m+1)} = \frac{1}{70} \sum_{i=1}^{70} \gamma_{ij}^{(m)}.$$

Визуализация результатов EM-флгоритма



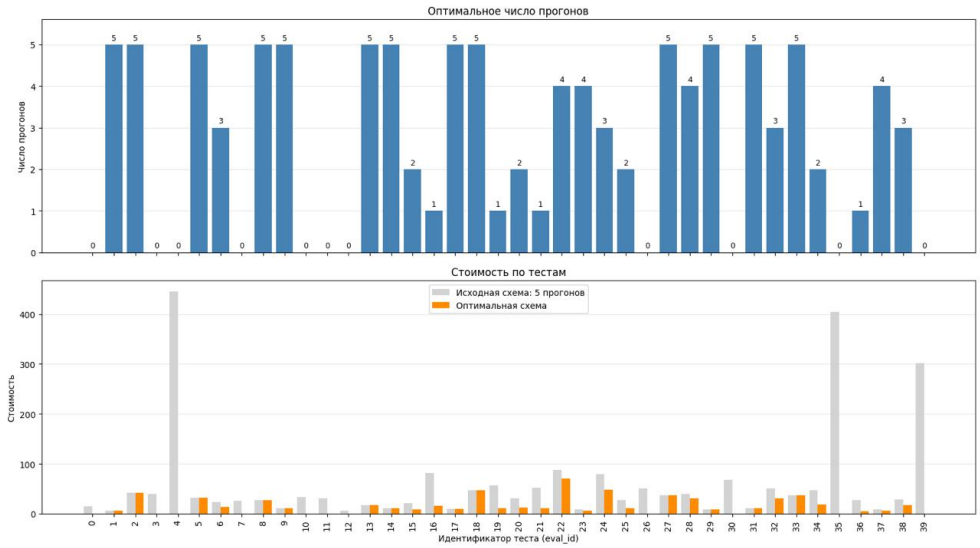
Задача оптимизации

$$\sum_{j=1}^{40} n_j c_j \to \min_{\vec{n}}$$

при условиях:

$$\begin{cases} \hat{\mathrm{FPR}}(\mathbf{n}) < \alpha, \\ n_j \in \{0, \ldots, 5\}, \quad j = 1, \ldots, 40. \end{cases}$$

Визуализация результатов оптимизации



Результаты оптимизации числа прогонов

Показатель	Исходная схема	Оптимальная схема
Стоимость прогонов	2378.55	611.17
Вероятность пропуска	3.0207%	4.9984%

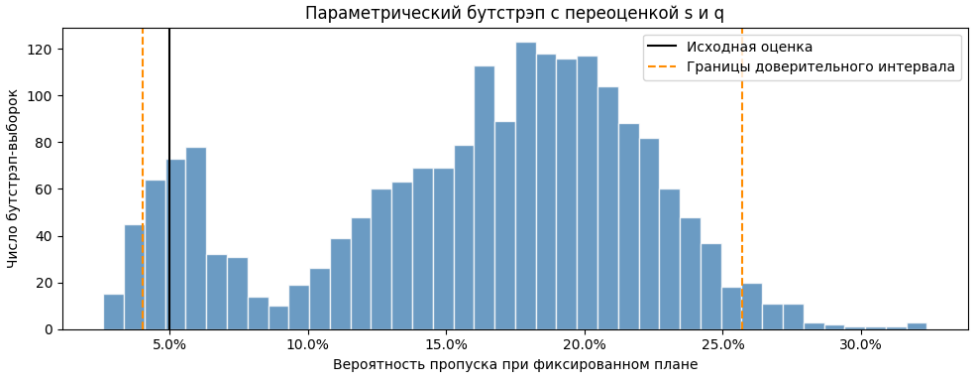
Экономия стоимости — 74.3%

Вероятность пропуска проблемного релиза остаётся в пределах заданного ограничения:

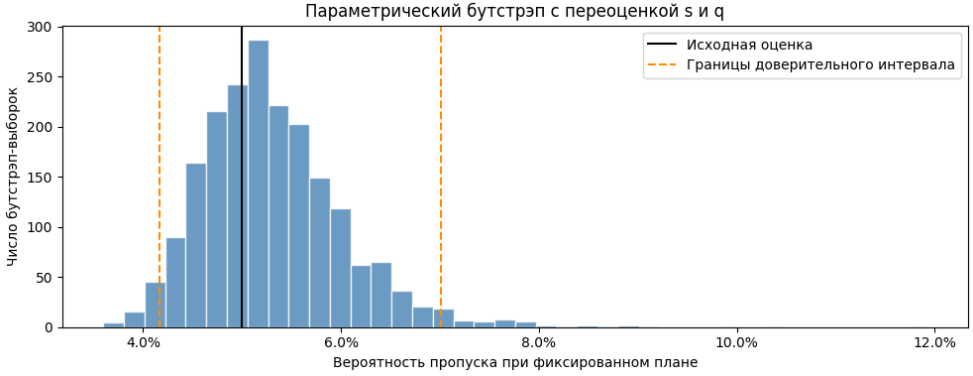
$$\mathrm{FPR}(\mathbf{n}) = 4.9984\% \leq \alpha = 5\%.$$

Исходная схема: по 5 прогонов каждого теста. Вероятности рассчитаны по оценённым параметрам модели, без учёта неопределённости их оценки.

Визуализация



Визуализация



Спасибо за внимание!