Экономия на эвалах

Elixi

условие задачи второго дня

Контекст

Чат — центр приложения Elixi: пользователь задаёт вопрос о здоровье, LLM-ассистент отвечает по его анализам, генетике и данным носимых устройств. Ассистент выпускается часто. Перед раскаткой новой версии прогоняются автотесты, а затем LLM-тесты (эвалы): сценарий с данными и вопросом пользователя, ответ новой версии ассистента, проверка ответа моделью-судьёй — зелёный или красный.

LLM-тесты долгие, случайные и дорогие: каждый прогон — минуты и токены ассистента и судьи, а один и тот же тест может и пройти, и не пройти. Сейчас на каждом релизе каждый из 40 тестов прогоняется 5 раз.

Что мы знаем о тестах

- Красный — настоящая проблема: ложных срабатываний не бывает.
- Если проблема есть, тест краснеет не на каждом прогоне: одни проблемы видны почти всегда, другие — редко.
- На релизе тест можно прогнать от 0 до 5 раз; каждый прогон оплачивается. Стоимости прогонов известны: от 1 до 90 за прогон.

Модель

Тест i, релиз j. Событие «в сценарии теста i на релизе j есть проблема» обозначим I_{ij}; считаем $I_{ij} \sim \mathrm{Bern}(p_i)$ независимо по тестам и релизам. Если $I_{ij} = 0$, все прогоны зелёные. Если $I_{ij} = 1$, каждый прогон независимо красный с вероятностью s_i. Параметры p_i и s_i неизвестны, стоимость прогона теста i — c_i. Релиз с проблемой — релиз, в котором проблема есть хотя бы в одном тесте. Такой релиз пропущен, если все запланированные прогоны всех тестов зелёные: план выпустил бы его как чистый.

Вопрос

Сколько раз гонять каждый тест — от 0 до 5, — чтобы пропускать как можно меньше релизов с проблемами и как можно больше экономить?

Данные

- `evals.csv`: `eval_id`, `cost` — 40 тестов и цена одного прогона.
- `dataset_train.csv`: `release_id`, `eval_id`, `run_no`, `red_flag` — история 70 релизов, на каждом каждый тест прогнан 5 раз, записан каждый прогон.

Формат ответа

- `plan.csv` со столбцами `eval_id`, `n_runs` — сколько раз гонять каждый тест, от 0 до 5.
- Презентация с постановкой, решением и обоснованием.

Оценивание

План применяется к `dataset_valid.csv` — 30 скрытым релизам в том же формате, у каждого теста записаны все 5 прогонов. Считаем, сколько релизов с проблемой план пропустил (среди пяти записей какого-то теста есть красный, но в первых `n_runs` прогонах всех тестов — только зелёные) и сколько он тратит на прогоны.