elixi

Школа по математической статистике

ЗАДАЧА ВТОРОГО ДНЯ

Экономия на эвалах

Сколько и как экономить токены при частых LLM-тестах

Виктор Харламов · **Data Scientist**

ПРОДУКТ

Чат — центр приложения

Пользователь задаёт вопрос — ассистент отвечает по его анализам, генетике и данным носимых устройств

Что чат должен делать

01 **Отвечать по данным**
его анализы, генетика и сон, а не общие советы

02 **Точность в фактах**
числа, единицы и нормы — как в анализах

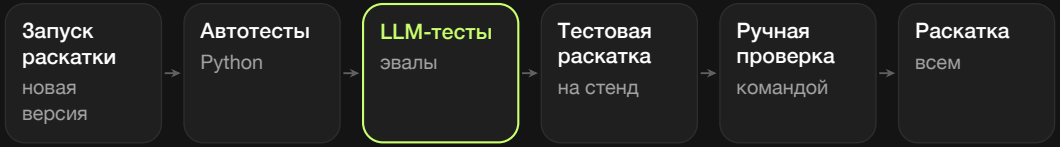
03 **Быть безопасным**
без диагнозов и назначений, вовремя к врачу

04 **Говорить понятно**
коротко, по делу, в тоне продукта



РЕЛИЗЫ

Как выкатывается новая версия



Автотесты — быстрые и почти бесплатные

Без случайности: результат всегда один и тот же

LLM-тесты — долгие, случайные и дорогие

Каждый прогон — минуты и токены ассистента и судьи, а результат может отличаться от раза к разу

LLM-ТЕСТЫ

Как устроен LLM-тест

Сценарий
данные и вопрос пользователя

→

Ответ
новой версии ассистента на этот сценарий

→

Проверка
ответ — свободный текст, его оценивает модель-судья

→

- зелёный
- красный

Пример

Сценарий: высокий холестерин
Проверка: по анализам, без назначений

Три особенности

Долго: минуты на один прогон
Случайно: тот же тест может и пройти, и нет
Дорого: токены ассистента и судьи

ЗАДАЧА

Сколько прогонов нам нужно?



LLM-тестов



прогонов каждого теста
на каждом релизе



релизов: 70 в истории
и 30 на проверку

Сколько раз гонять каждый тест — от 0 до 5, — чтобы пропускать как можно меньше релизов с проблемами и как можно больше экономить?

ЧТО ВЫДАЁТСЯ

Данные

`evals.csv`

40 LLM-тестов и цена одного прогона

eval_id	cost
0	2.83
1	1.17
2	8.38
3	7.90
…	

`dataset_train.csv`

70 релизов, каждый тест прогнан 5 раз, записан каждый прогон

Строки первого релиза:

release_id	eval_id	run_no	red_flag
0	0	0	0
0	0	1	0
…			
0	8	0	0
0	8	1	1
…			

КАК ПРОВЕРЯЕМ

Формат ответа и оценивание

Ответ

`plan.csv`

Прогонов на тест: от 0 до 5

eval_id	n_runs
0	0
1	5
2	5
…	

Проверка

`dataset_valid.csv`

30 скрытых релизов в том же формате

На каждом применяем план и считаем:

- **пропущено** — релизы с проблемой, где все прогоны плана зелёные
- **потрачено** — стоимость прогонов плана