Задача B «Экономия на эвалах»: решение

ограничение на долю пропущенных релизов с проблемами

для организаторов

25 октября 2026

Что решаем

На релизе выполняются все запланированные прогоны: тест i — n_i раз. Если хоть один прогон красный, релиз уходит на доработку; если все зелёные, релиз выпускается. Плохо, если выпущен релиз с проблемой — в нём есть проблема хотя бы в одном тесте. Требование организаторов — на вероятность пропуска *при условии, что релиз проблемный*:

$$\pi_{\mathsf{c}}(n) = \mathsf{P}(\text{все прогоны плана зелёные} \mid \text{релиз с проблемой}) = \frac{\pi(n)}{P_1} \le \alpha = 0.1,$$

где $\pi(n) = \mathsf{P}(\text{релиз с проблемой, а все прогоны плана зелёные})$ и $P_1 = 1 - \prod_i (1 - p_i)$, с вероятностью не меньше 0.9 по истории; стоимость плана — $\sum_i c_i n_i$. В мире задачи $P_1 = 0.81$, так что в безусловных терминах требование — $\pi(n) \le \alpha P_1 = 0.081$. Команды P_1 не знают и оценивают сами: по модели ($1 - \prod(1 - \hat{p}_i) = 0.84$ на опубликованной истории) или по доле релизов истории с красным ($56/70 = 0.80$). Командам устно названо «5–10%»; на валидации считается число пропущенных релизов среди проблемных и стоимость.

Схема решения.

1. Один релиз: формула для $\pi(n)$ (раздел 1).
2. Известные параметры: после логарифма — рюкзак; пороговое правило (раздел 2).
3. Что можно оценить по данным: видимая часть π оценивается несмещённо, невидимая — никак (раздел 3).
4. Оценки по тесту: ОММ, ОМП, частоты; в этом мире событий мало, и это главная трудность (раздел 4).
5. Погрешность при фиксированном плане (раздел 5).
6. Контроль ожидаемого числа упущенных проблем вместо π (раздел 6).
7. Отбор плана по тем же данным: бутстреп всей процедуры и точная проверка на отложенных релизах (раздел 7).
8. Мир задачи, результаты, оценивание ответов (разделы 8–10).

Обозначения

$i = 1, \dots, M$, $M = 40$	тесты
c_i	стоимость одного прогона теста i
p_i	вероятность того, что в сценарии теста i на релизе есть проблема
s_i	вероятность того, что прогон покраснеет, если проблема есть (без проблемы прогон всегда зелёный)
$n_i \in \{0, \dots, 5\}$, n	сколько раз гонять тест i; вектор n — *план*
$g_i(m) = 1 - p_i + p_i(1 - s_i)^m$	вероятность того, что первые m прогонов теста i зелёные
$\pi(n)$, $\pi_{\mathrm{c}}(n) = \pi(n)/P_1$	вероятность пропустить релиз с проблемой при плане n: по всем релизам и при условии, что релиз проблемный
$P_0 = \prod_i (1 - p_i)$, $P_1 = 1 - P_0$	вероятности чистого и проблемного релиза
$K_{ij} \in \{0, \dots, 5\}$	число красных среди пяти записей теста i на релизе j истории
$C(n) = \sum_i c_i n_i$	стоимость плана
$\mathbf{5}$	план «каждый тест 5 раз»
$\alpha = 0.1$, $\gamma = 0.1$	допустимая доля пропущенных среди проблемных релизов; допустимая вероятность того, что правило ошибётся
$\bar{\varepsilon} = 0.02$	предположение: $\pi(\mathbf{5}) \le \bar{\varepsilon}$
$N_{\mathrm{h}} = 70$	релизов в истории; на каждом все тесты прогнаны 5 раз

1. Один релиз

Тесты независимы, поэтому все прогоны плана зелёные с вероятностью $\prod_i g_i(n_i)$. Из этого события вычитаем чистый релиз (проблем нет — все прогоны зелёные), его вероятность $\prod_i (1 - p_i)$:

$$\boxed{\pi(n) = \prod_i g_i(n_i) - \prod_i (1 - p_i).}$$

В отличие от ожидаемого числа упущенных проблем, π не складывается по тестам: релиз с двумя проблемами пропускается, только если упущены обе. Поэтому ловить нужно не каждую проблему, а хотя бы одну на релизе.

2. Если бы параметры были известны

$$\min_n \sum_i c_i n_i \qquad \text{при} \qquad \pi(n) \le \alpha P_1.$$

Ограничение равносильно $\prod_i g_i(n_i) \le \alpha P_1 + P_0 = \alpha + (1 - \alpha) P_0$. После логарифма

$$\sum_i D_i(n_i) \;\ge\; B, \qquad D_i(n) = -\log g_i(n), \qquad B = -\log\bigl(\alpha + (1 - \alpha) P_0\bigr)$$

— слева сумма по тестам, справа константа. Это рюкзак: k-й прогон теста i — предмет со стоимостью c_i и пользой

$$d_i(k) = D_i(k) - D_i(k - 1) = -\log\bigl(1 - r_i(k)\bigr), \qquad r_i(k) = \frac{p_i s_i (1 - s_i)^{k-1}}{1 - p_i + p_i (1 - s_i)^{k-1}},$$

где $r_i(k)$ — вероятность того, что k-й прогон покраснеет, если предыдущие прогоны теста зелёные.

Лемма 1. $d_i(1) \ge d_i(2) \ge \cdots \ge d_i(5)$.

Доказательство. При $x = (1 - s_i)^{k-1}$ величина $r_i(k) = p_i s_i x/(1 - p_i + p_i x)$ возрастает по x, а x убывает по k. □

Теорема 1. *Если брать прогоны по убыванию $d_i(k)/c_i$, пока не выполнится $\sum_i D_i(n_i) \geq B$, получится план не дороже оптимального плюс стоимость одного прогона: $C(n^{\text{gr}}) \leq C^* + \max_i c_i$.*

Доказательство. Непрерывная релаксация — рюкзак с $x_{ik} \in [0, 1]$; её оптимум — брать предметы по убыванию d/c, последний частично. По лемме внутри теста $d_i(k)/c_i$ убывает, поэтому k-й прогон берётся только после $(k-1)$-го, и решение релаксации — план стоимостью не больше C^*. Жадный план отличается последним предметом, взятым целиком. □

Пороговое правило. При пороге λ тест гоняется k-й раз, если $d_i(k)/c_i \geq \lambda$: вероятность того, что прогон поймает проблему, в расчёте на рубль выше порога. Почти неломающиеся тесты не гоняются, точные — один раз, часто ломающиеся с умеренной s_i — несколько раз. Точный оптимум — целочисленное линейное программирование с ограничениями $\sum d_i(k) x_{ik} \geq B$, $x_{i,k} \leq x_{i,k-1}$. Жадный план в мирах задачи дороже точного в среднем на 1.1%, в худшем из 20 миров — на 6% (оценка $C^* + \max_i c_i$ грубая: самый дорогой прогон — пятая часть стоимости оракула). Оракул стоит в среднем 0.85 от нынешней практики «все по разу» (у неё $\pi_{\text{c}} \approx 0.25$) и 0.17 от «все по 5»; в мире 24 — 0.91 и 0.18.

3. Что можно оценить по данным

На релизе истории записаны все пять прогонов каждого теста, поэтому для плана n видно событие

$$V_j(n) = \{\text{первые } n_i \text{ записей каждого теста зелёные, но среди всех записей есть красный}\}$$

— «план пропустил бы релиз, а пятикратный прогон поймал бы проблему».

Лемма 2 (разложение). $\rho(n) = \mathsf{P}(V(n)) = \prod_i g_i(n_i) - \prod_i g_i(5)$, и $\pi(n) = \rho(n) + \pi(\mathbf{5})$.

Доказательство. Событие «зелёные все пять записей всех тестов» вложено в «зелёные все прогоны плана», разность — $V(n)$. Кроме того, $\pi(\mathbf{5}) = \prod_i g_i(5) - \prod_i (1 - p_i)$. □

Несмещённая оценка видимой части. Пусть $h(k, m) = \binom{5-m}{k} \big/ \binom{5}{k}$ — вероятность того, что m случайных записей из пяти зелёные, если красных k (при $k = 0$ это 1). Тогда

$$\hat{\rho}(n) = \frac{1}{N_{\text{h}}} \sum_j \Big[\prod_i h(K_{ij}, n_i) - \mathbb{1}\{K_{\cdot j} = 0\} \Big]$$

несмещённо оценивает $\rho(n)$: тесты независимы, а $\mathbb{E}\, h(K, m) = \mathsf{P}(\text{первые } m \text{ прогонов зелёные})$.

Утверждение 1 (невидимую часть оценить нельзя)**.** *Ни p_i, ни s_i, ни $\pi(n)$ не имеют несмещённых оценок ни при каком числе релизов.*

Доказательство. По одному тесту достаточная статистика — мультиномиальный вектор частот $K = 0, \ldots, 5$ с вероятностями $P_0, \ldots, P_5$; несмещённо оцениваются только многочлены от них. При $k \geq 1$ в P_k есть множитель s, а $P_0 = 1 - \sum_{k \geq 1} P_k$, поэтому любой такой многочлен при $s \to 0$ стремится к константе, а $1 - g(m) = p\big(1 - (1 - s)^m\big) \to 0$ при любом p. Значит, π при $s_1 \to 0$ зависит от p_1, а данные — нет. Для s — симметрично при $p \to 0$: данные вырождаются в $K \equiv 0$ при любом s. □

Поэтому «пяти прогонов хватает» входит в постановку предположением $\pi(\mathbf{5}) \leq \bar{\varepsilon} = 0.02$ (в мирах генератора в среднем 0.012, максимум 0.014 на 60 мирах), и требование сводится к видимой части: $\rho(n) \leq \alpha P_1 - \bar{\varepsilon}$ ($= 0.061$ в мире задачи).

4. Оценки по тесту

Для теста на релизе $\mathsf{P}(K=0) = 1-p+p(1-s)^5$, $\mathsf{P}(K=k) = p\binom{5}{k}s^k(1-s)^{5-k}$ при $k \geq 1$.

- **ОММ.** Средние по релизам величин $K/5$ и $K(K-1)/20$ — a и b — несмещённо оценивают ps и ps^2; $\hat{s} = b/a$, $\hat{p} = a^2/b$. Если у теста нет релиза с двумя красными ($b = 0$), берётся общая по тестам $\hat{s} = \sum b / \sum a$.
- **ОМП (EM).** На релизе с $K = 0$ апостериорная вероятность проблемы $q = pz/(1-p+pz)$, $z = (1-s)^5$; шаг: $W = n_{K\geq 1} + n_{K=0}\, q$, $p \leftarrow W/N_{\text{h}}$, $s \leftarrow \sum K/(5W)$.
- **Частоты.** Без модели — оценка $\hat{\rho}$ выше.

Главная трудность. В мире задачи 80% релизов проблемные, но тестов 40, поэтому у отдельного теста $p_i \approx 0.02$–0.06. В опубликованной истории у типичного теста 2 релиза с красным, у 9 тестов — ни одного, у 21 — не больше двух. Отсюда:

- ОМП часто уходит на границу: если все релизы с проблемой дали по одному красному, $\hat{p} \to 1$, $\hat{s} \to 0$, и тест выглядит «ломается всегда, но не видно»; такой план гоняет всё;
- ОММ делит на малую и шумную b и в среднем завышает π — это перестраховка;
- частоты несмещённые, но у теста без событий вклад ровно 0 — как и у ОММ и ОМП ($\hat{p} = 0$ при $a = 0$): ни одна оценка по данным не гоняет пять реально ломающихся тестов без событий (в мире 24 это тесты $0, 3, 4, 12, 30$; пять таких тестов из девяти — типично, ожидается 3.3).

Последнее — потолок для всех методов по данным, а не ловушка для наивных: оракул гоняет три из этих тестов, и их обнуление поднимает π с 0.100 до 0.126 при экономии 0.009 от полной проверки. Лечится общим априорным распределением по тестам (пулинг, эмпирический Байес) или одним прогоном дешёвых тестов без событий.

5. Погрешность при фиксированном плане

Погрешность оценки π для заданного плана считается дельта-методом (для ОММ — по выборочной ковариации пар $(K/5, K(K-1)/20)$ каждого теста; для ОМП — по информации Фишера одного релиза), бутстрепом по релизам или, для частот, как погрешность среднего по релизам.

план	оценка	смещение	разброс	оценённая погрешность / настоящая	покрытие границы 90%
все дважды	ОММ	$+26\%$	20%	0.92	0.99
	ОМП	$+168\%$	86%	—	1.00
	частоты*	0%	25%	0.96	0.84
план оракула	ОММ	$+20\%$	19%	0.97	0.98
	ОМП	$+146\%$	75%	—	0.99
	частоты*	0%	29%	1.01	0.84

* оценивают видимую часть ρ. 10 миров по 60 историй. ОМП вырождается на тестах с малым числом событий, и его погрешность по информации Фишера бессмысленна. ОММ перестраховывается; частоты несмещены, но при малом числе событий сумма скошена, и нормальная граница недопокрывает.

6. Контроль ожидаемого числа упущенных проблем вместо π

Естественная подмена — требовать $\mathbb{E}N(n) = \sum_i p_i(1-s_i)^{n_i} \leq \alpha P_1$ или $\mathsf{P}(N \geq 1) \leq \alpha P_1$ (или те же величины, делённые на P_1, не больше α), где N — число упущенных проблем. Так

как пропуск релиза означает, что упущены все его проблемы,

$$\pi(n) \le \mathsf{P}(N(n) \ge 1) \le \mathbb{E}N(n),$$

и обе подмены консервативны. В этом мире они очень дороги: релиз часто содержит несколько проблем, и поймать одну из них достаточно, а $\mathbb{E}N$ требует ловить каждую. В мире задачи $\mathbb{E}N(\mathbf{5}) \approx 0.06$ сравнимо с $\alpha P_1 = 0.08$, поэтому план с $\mathbb{E}N \le \alpha P_1$ совпадает с полной проверкой.

7. Отбор плана по тем же данным

Проклятие победителя. План выбирается по тем же оценкам, и среди дешёвых планов чаще проходит тот, у которого оценка случайно занижена. Запас, посчитанный для фиксированного плана (дельта-метод), этого не учитывает.

Бутстреп всей процедуры.
1. перевыбрать 70 релизов истории с возвращением;
2. на перевыборке заново оценить параметры и построить жадный путь планов;
3. для каждого запаса c из сетки взять самый дешёвый план с оценкой π не больше $\alpha - c$ и проверить, укладывается ли он в α по оценкам на *полной* истории;
4. повторить $B = 40$ раз и взять наименьший c, при котором план укладывается в 90% повторов;
5. на полной истории взять самый дешёвый план с оценкой не больше $\alpha - c$.

Запас учитывает и шум оценок, и отбор; гарантия приближённая.

Проверка на отложенных релизах (точно).
1. История случайно делится на обучающую (35 релизов) и проверочную ($m = 35$) части.
2. По обучающей — оценки и жадный путь планов $\mathbf{0} = n^{(0)} \le \cdots \le n^{(K)} = \mathbf{5}$.
3. По проверочной: S_k — число релизов, которые план $n^{(k)}$ пропустил бы (событие V). Идём от $\mathbf{5}$ к дешёвым планам, пока верхняя граница Клоппера–Пирсона $U_\gamma(S_k, m) \le \alpha\hat{P}_1 - \bar{\varepsilon}$, где $\hat{P}_1$ — оценка доли проблемных релизов по обучающей части.
4. Ответ — последний принятый план.

Теорема 2. *Для любых параметров с $\pi(\mathbf{5}) \le \bar{\varepsilon}$ правило с порогом $\alpha P_1 - \bar{\varepsilon}$ выбирает план с $\pi \le \alpha P_1$ с вероятностью не меньше $1 - \gamma$ (с оценкой $\hat{P}_1$ вместо P_1 гарантия приближённая).*

Доказательство. При фиксированной обучающей части путь неслучаен, а $S_k \sim \mathrm{Bin}(m, \rho(n^{(k)}))$, и ρ монотонно убывает вдоль пути. Пусть k^* — наибольший номер с $\rho(n^{(k^*)}) > \alpha P_1 - \bar{\varepsilon}$. Ответ плохой, только если правило приняло k^*, то есть $U_\gamma(S_{k^*}, m) \le \alpha P_1 - \bar{\varepsilon} < \rho(n^{(k^*)})$; по свойству границы Клоппера–Пирсона вероятность этого не больше γ. Иначе $\pi = \rho + \pi(\mathbf{5}) \le \alpha P_1$. □

При $m = 35$ и $\alpha\hat{P}_1 - \bar{\varepsilon} \approx 0.06$ правило принимает план, только если на проверочных релизах он не пропустил ни одного ($U_{0.1}(0, 35) = 0.064$, $U_{0.1}(1, 35) = 0.107$). Гарантия точная, но дорогая.

8. Мир задачи

архетип	тестов	s_i	p_i	стоимость (множитель)
идеальный	6	0.80–0.95	0.022–0.050	1
стеснительный	6	0.35–0.50	0.022–0.050	1
слабый	3	0.30–0.45	0.022–0.050	1
дорогой точный	3	0.90–0.99	0.022–0.058	10
дешёвый средний	12	0.35–0.55	0.022–0.050	0.3
не ломается	5	0.85–0.95	0–0.0014	1
часто ломается	5	0.45–0.65	0.090–0.144	1

Базовая стоимость прогона — логнормальная с медианой 8 и $\sigma = 0.4$, умноженная на множитель. Опубликованный мир — seed 24; его стоимости совпадают с уже выданным `evals.csv` (стоимости в генераторе зависят только от seed и долей архетипов). История — 70 релизов, валидация — 30. В мире 24 доля релизов с проблемой 0.81 (в истории 56 из 70, на валидации 25 из 30), в среднем 1.6 проблемы на релиз; $\pi(\mathbf{1}) = 0.207$ ($\pi_c = 0.256$), $\pi(\mathbf{5}) = 0.012$ ($\pi_c = 0.015$); требование $\pi_c \le 0.1$ — это $\pi \le 0.081$.

9. Что получается

60 миров, по одной истории и одной валидации в каждом. Стоимость — в долях от «все по 5»; «пропущено» — среднее число пропущенных релизов с проблемой на 30 релизах валидации (из них в среднем 24 проблемные; считаются видимые пропуски, $\mathrm{Bin}(30, \pi - \pi(\mathbf{5}))$, у плана с $\pi_c = 0.1$ ожидается около 2.1). Столбец π_c — истинная условная вероятность. Каждый метод целится в $0.1 \cdot \hat{P}_1$ по своей оценке $\hat{P}_1$. Расчёт — `evals_task/numbers.py`.

решение	π_c	миров с $\pi_c \le 0.1$	стоимость	пропущено из 30
все по разу	0.248	0	0.20	5.4
частоты, подстановка	0.283	0	0.10	6.1
общая s для всех тестов	0.186	0	0.12	3.8
ОММ, подстановка	0.138	0.08	0.17	2.6
ОММ, дельта-метод	0.114	0.32	0.21	2.1
ОММ, бутстреп-квантиль без переотбора	0.106	0.42	0.22	1.9
ОММ, подстановка с целью $\alpha/2$	0.072	0.88	0.37	1.1
ОММ, бутстреп всей процедуры, уровень 0.9, $B = 40$	0.074	0.75	0.38	1.1
ОММ, бутстреп всей процедуры, уровень 0.95, $B = 100$	0.067	**0.90**	**0.41**	1.1
ОМП: подстановка / дельта / бутстреп	0.04–0.05	0.73–0.80	0.78	0.5–0.8
контроль $\mathbb{E}N$ / $\mathsf{P}(N \ge 1)$	0.015	1	0.98 / 0.97	0
все по 2	0.104	0.25	0.40	2.3
отложенные релизы, Клоппер–Пирсон	0.034	0.98	0.77	0.4
оракул	0.100	1	0.17	1.9
все по 5	0.015	1	1	0

- **Подстановки** не дороже оракула, но в требование почти не укладываются; частоты хуже нынешней практики — тесты без событий не гоняются вовсе. Подстановка доли пропущенных релизов прямо по истории (без модели) переобучается: $\pi_c = 0.31$ при цели 0.1.
- **ОМП** вырождается и почти всё гоняет: надёжно, но дорого — случайная перестраховка, а не метод.

- **Контроль $\mathbb{E}N$ или $\mathsf{P}(N \geq 1)$** вместо π не экономит: подмена критерия стоит 0.97–0.98 полной проверки. Та же подмена без модели — доля релизов истории, где план упустил хоть одну проблему, — даёт $\pi_{\mathsf{c}} = 0.07$ при цене 0.37: надёжно, но вдвое дороже оракула.
- **Эталон** — ОММ и бутстреп всей процедуры с уровнем 0.95 и $B = 100$: укладывается в 90% миров, в 2.4 раза дороже оракула и на 59% дешевле полной проверки. С уровнем 0.9 и $B = 40$ бутстреп не дотягивает (0.75): при двух событиях на тест он недооценивает разброс. Грубая альтернатива — наивная подстановка с целью $\alpha/2 = 0.05$: укладывается в 0.88 миров при стоимости 0.37; запас по бутстрепу в этом режиме не лучше запаса «вдвое», разница — в обосновании.
- **Отложенные релизы** дают точную гарантию за 0.77.
- **«Все по** 2**»** при условном критерии уже не база: $\pi_{\mathsf{c}} = 0.104$, укладывается лишь в четверти миров.
- **Вырожденный план** «15 самых часто красных тестов по 3 прогона» имеет $\pi_{\mathsf{c}} = 0.28$ и проходит порог в 17% выборок — на опубликованной ему повезло.

Опубликованные данные. Мир фиксирован стоимостями, поэтому выбиралась реализация истории и валидации: из 300 реализаций — та, на которой при безусловном критерии лестница решений была видна и по истине, и на валидации, а стоимость эталона близка к типичной для мира. При условном критерии цели всех методов сдвинулись, и на той же валидации наивная подстановка ОММ проходит порог; реализацию не меняли, потому что история уже выдана. Данные — `data/B_rel_s24`; запасные реализации — `data/B_rel_s24_d146` и `data/B_rel_s24_d153`; планы всех решений — `hidden/plans`.

решение (мир 24)	π_{c}	пропущено из 25	проходит порог 3	стоимость	прогонов
все по разу	0.256	7	нет	0.20	40
частоты, подстановка	0.277	5	нет	0.10	52
общая s	0.213	5	нет	0.12	56
ОМП, подстановка	0.174	4	нет	0.15	73
ОММ, подстановка	0.166	3	да	0.15	74
ОММ, дельта-метод	0.122	1	да	0.20	88
ОМП, дельта-метод	0.126	2	да	0.19	88
ОММ, бутстреп-квантиль	0.122	1	да	0.20	88
ОММ, подстановка с целью $\alpha/2$	0.080	0	да	0.30	107
ОММ, бутстреп всей процедуры (уровни 0.9 и 0.95 дали один план)	0.065	0	да	0.35	115
все по 2	0.108	4	нет	0.40	80
контроль $\mathbb{E}N$	0.015	0	да	1	200
отложенные релизы	0.021	0	да	0.71	191
оракул	0.100	0	да	0.18	86

На 200 историях этого мира эталон (уровень 0.95) укладывается в требование в 87% случаев (82–91%) при средней стоимости 0.42, бутстреп с уровнем 0.9 — в 76% (70–81%) при 0.36; дельта-метод — в 25%, наивная подстановка ОММ — в 2.5% (средняя цена 0.18).

10. Как оценивать ответы

Ответ команды — `plan.csv` (`eval_id`, `n_runs`). На 30 скрытых релизах (`dataset_valid.csv`) записаны все пять прогонов; релиз с проблемой — тот, где хоть у одного теста среди пяти записей есть красный. Считаются (`evals_task/score.py`):

- **пропущено** — релизы с проблемой, на которых первые n_i записей всех тестов зелёные;

• **потрачено** — $\sum_i c_i n_i$.

План проходит, если пропустил не больше 3 релизов; прошедшие ранжируются по стоимости, не прошедшие — после них. Считаются видимые пропуски, поэтому их число — $\mathrm{Bin}(30, \rho)$ с $\rho = \pi_c P_1 - \pi(\mathbf{5}) = 0.81\,\pi_c - 0.012$; у плана с $\pi_c = 0.1$ среднее 2.1, и порог 3 — его 80%-квантиль. Вероятность пройти порог 3: при $\pi_c = 0.05$ — 0.99, 0.08 — 0.93, 0.10 — 0.85, 0.13 — 0.69, 0.15 — 0.58, 0.20 — 0.32, 0.30 — 0.06. То есть порог надёжно отсекает лишь $\pi_c \gtrsim 0.2$; между 0.1 и 0.17 исход — в значительной мере удача.

Разбор. Решено оставить 30 релизов и раскрыть истину на разборе: для каждого плана команды показать истинную условную вероятность пропуска (`python3 -m evals_task.score ... --exact`, столбец P(miss|prob)) рядом с числом пропущенных и честно сказать, что на 30 релизах между $\pi_c = 0.1$ и 0.17 исход — во многом удача. Примеры на опубликованных данных: наивная подстановка ОММ с целью 0.1 даёт $\pi_c = 0.166$, но пропускает лишь 3 из 25 и проходит порог дешевле оракула — такая удача у неё случается примерно в половине выборок; план «15 самых часто красных тестов по 3 прогона» пропускает 2 из 25 и стоит 0.13, а по истине пропускает 29% проблемных релизов; подстановка доли пропущенных релизов по истории с целью 0.1 переобучается — 8 пропусков, $\pi_c = 0.33$; подстановка $\mathsf{P}(N \geq 1)$ по истории даёт $\pi_c = 0.131$ и 5 пропусков.

Что валидация различает. Дешёвые и грубые решения (частоты, общая s, «все по разу») пропускают 4–8 релизов и отделяются уверенно. Наивная подстановка ОММ превышает α в 1.3–1.7 раза — на 30 релизах это видно лишь в части миров, и на опубликованной реализации при условном критерии не видно; честное сравнение методов — по истинным параметрам на многих мирах (таблица выше).